

MoE核心原理

30分钟精华版

封面

MoE稀疏模型解析

从历史演进理解混合专家模型

分享人: [你的名字]

时长: 30分钟

日期: 2025

符号表（核心符号）

符号	定义	说明
N	专家数量	总专家数
K	Top-K激活数	每个token激活的专家数
$E_i(x)$	第 i 个专家网络	FFN结构
$G(x)$	门控函数	输出专家权重分布
d_{model}	模型隐藏维度	Transformer隐藏层大小
d_{ff}	前馈网络中间维度	通常 $d_{ff} = 4 \cdot d_{model}$

关键公式: $y = \sum_{i \in \text{TopK}(G(x), K)} g_i(x) \cdot E_i(x)$

议程

1. MoE的核心问题与价值 (3 min)
2. 历史演进: 四个关键阶段 (15 min)
3. 现代MoE架构全景 (8 min)
4. 总结与展望 (4 min)

Part 1: MoE的核心问题与价值

1.1 大模型的困境

Scaling Law的启示

模型越大，效果越好

$$L(N) \propto \frac{1}{N^\alpha}, \quad \alpha \approx 0.076$$

但成本线性增长：

模型参数	训练FLOPs	推理成本
7B	1x	1x
70B	10x	10x
700B	100x	100x

核心问题：能否打破参数–计算的线性关系？

1.1 大模型的困境（续）

Dense模型的限制

数学表达：

$$\text{FLOPs}_{dense} = \Theta(N_{params})$$

困境：

- 想要更大模型 → 需要更多参数
- 更多参数 → 更多计算
- 更多计算 → 更高成本

能否打破？

- 增加参数但不增加计算？
- $N_{params} \uparrow$ 但 $\text{FLOPs} \approx \text{const}$?

1.2 MoE的核心思想

答案：稀疏激活

核心公式：

$$y = \sum_{i \in \text{TopK}(G(x), K)} g_i(x) \cdot E_i(x)$$

关键洞察：只激活 K 个专家 ($K \ll N$)

1.2 MoE的核心思想（对比）

Dense vs MoE

Dense Model

输入 x
↓
FFN (100%参数)
↓
输出

计算: 100%

MoE Model (N=8, K=2)

输入 x
↓
Router (选Top-2)
↓
Expert 1 + Expert 4
↓
输出

1.3 MoE的价值

效率对比

指标	Dense	MoE	提升
参数	P	$N \cdot P$	N 倍
计算	C	$K \cdot C$	K 倍
性价比	1	$\frac{N}{K}$	$\frac{N}{K}$ 倍

1.3 MoE的价值（案例）

Mixtral 8x7B 实际效果

配置: $N = 8, K = 2$, 基础模型 7B

指标	数值
总参数	47B
激活参数	13B
效果	接近 LLaMA-2 70B
推理成本	接近 13B Dense模型
性价比	4倍

结论: 相同计算量下, MoE获得 $\frac{N}{K}$ 倍参数容量

Part 2: 历史演进 – 四个关键阶段

2.1 历史总览

年份	里程碑	关键创新
1991	原始MoE	概念提出，分而治之
2017	Shazeer et al.	稀疏激活，深度学习首次成功
2021	Switch Transformer	简化设计，万亿参数
2024	Mixtral	工业落地，开源标杆
2024	DeepSeek	细粒度专家、共享专家，训练稳定性突破
2025	DeepSeek-V3.2	DSA稀疏注意力+MoE，双重稀疏，接近GPT-5

阶段一: 1991–2016 原始MoE

历史背景: 1991年计算资源有限 (CPU ~50 MIPS, MB级内存)

核心问题: 如何在有限资源下处理复杂任务?

Jacobs的洞察: 分而治之

2.2 Jacobs et al. 1991 – 概念诞生

论文：Adaptive Mixtures of Local Experts

核心思想：分而治之

数学框架：

$$y = \sum_{i=1}^N g_i(x) \cdot E_i(x)$$

关键创新：

1. 混合模型：多个专家加权组合
2. 自适应门控：动态选择专家
3. 局部专业化：专家学习不同区域

经典架构图（Jacobs 1991）

论文：Adaptive Mixtures of Local Experts (1991)

2.3 原始MoE的问题

问题	描述	影响
问题1	所有专家都参与计算	没有计算效率提升
问题2	专家坍缩（Expert Collapse）	其他专家被"饿死"
问题3	规模受限	难以扩展到大量专家

2.3 原始MoE的问题（详解）

问题1：计算效率

$$\text{FLOPs}_{1991} = N \cdot \text{FLOPs}_{expert}$$

结论：计算量与专家数量线性增长

问题2：专家坍塌

训练后门控总是选同一个专家：

$$\lim_{t \rightarrow \infty} g_i(x_t) \rightarrow \begin{cases} 1 & i = i^* \\ 0 & \text{otherwise} \end{cases}$$

原因：正反馈循环 + 缺乏约束

问题3：规模受限

梯度传播困难 + 内存限制 + 训练不稳定

阶段二: 2017 Sparsely-Gated MoE

历史背景: 深度学习时代的到来

2017年的技术环境:

- Transformer架构: Vaswani et al. 2017 提出Attention机制
- 大规模数据: ImageNet、大规模文本语料库
- 计算资源: GPU集群、TPU可用
- 模型规模: 从百万参数到十亿参数

核心问题: 如何在保持计算效率的同时, 进一步扩大模型规模?

Shazeer et al. 的突破: 稀疏激活 + 负载均衡

2.4 Shazeer et al. 2017 – 突破性工作

论文: Outrageously Large Neural Networks

核心贡献: 首次在深度学习时代成功应用稀疏MoE

2.4 三大创新 (1/3)

1. 稀疏门控 (Sparse Gating)

$$G(x) = \text{SparseTopK}(\sigma(x^T W_g), K)$$

效率：从 N 倍计算 $\rightarrow K$ 倍 ($K = 2, N = 128$)

效果：计算量降低64倍！

2.4 三大创新 (2/3)

2. Noisy Top-K Gating

$$\text{logits} = x^T W_g + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \sigma^2)$$

作用：

- 训练时：噪声促进探索
- 推理时：无噪声，确定性路由

目的：防止专家坍缩

2.4 三大创新 (3/3)

3. 辅助损失 (Auxiliary Loss)

$$\mathcal{L}_{aux} = N \cdot \sum_{i=1}^N \text{Importance}_i \cdot \text{Load}_i$$

目标：每个专家处理约 $\frac{1}{N}$ 的token

作用：显式惩罚负载不均衡

2.5 Noisy Top-K Gating

核心步骤:

1. 计算原始logits: `logits = x @ W_gate`
2. 添加可学习噪声: `logits += noise * randn()` (训练时)
3. Top-K选择: `top_k = logits.topk(k)`
4. Softmax归一化: `gates = softmax(top_k)`

为什么加噪声? 让不同token有机会选择不同专家, 避免"富者愈富"

2.6 辅助损失: 负载均衡

核心公式:

$$\mathcal{L}_{aux} = N \cdot \sum_{i=1}^N (\text{Importance}_i \cdot \text{Load}_i)$$

目标: 每个专家处理约 $\frac{1}{N}$ 的token

总损失: $\mathcal{L}_{total} = \mathcal{L}_{main} + \alpha \cdot \mathcal{L}_{aux}$

其中 α 通常设为 0.01 – 0.1

2.7 2017经典架构图

Shazeer et al. 2017 稀疏门控MoE架构

论文: Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer (2017)

Shazeer 2017
Sparse MoE Architecture
()

2.8 2017的成果与局限

成果

指标	数值
参数量	137B（总参数）
激活参数	~2B（Top-2, 1.5%）
计算效率	68倍提升
性能	机器翻译SOTA

意义：首次成功应用稀疏MoE

2.8 2017的局限

局限	影响
架构	基于LSTM，非Transformer
训练	不稳定，需要精细调参
负载均衡	不完美，专家可能"饿死"
扩展性	难以扩展到>1000专家

历史意义：为后续工作奠定基础

阶段三: 2021–2022 Switch Transformer

历史背景: 大规模预训练时代

2021年的技术环境:

- GPT-3 (175B): 证明了大规模预训练的有效性
- Transformer成熟: 成为NLP的标准架构
- 计算资源丰富: TPU v3/v4, 大规模GPU集群
- 数据规模: T级tokens的训练数据

核心问题: 如何将MoE扩展到万亿参数规模?

Fedus et al. 的设计哲学: 简化一切 (Simplify Everything)

2.9 Switch Transformer – 极简设计

论文: Switch Transformers: Scaling to Trillion Parameter Models

设计哲学: 简化一切

2.9 关键改进对比

维度	Shazeer 2017	Switch 2021	改进
Top-K	K=2	K=1	简化计算
Gating	Noisy Top-K	简单softmax	减少超参数
辅助损失	复杂形式	简化形式	降低调参
架构	LSTM	Transformer	并行优势
规模	137B	1.6T	可扩展性

2.9 为什么Top-1可行?

三个条件:

1. 足够多的专家: N 足够大
2. 足够多的tokens: 大规模数据
3. 训练稳定性: Top-1梯度路径更简单

数学保证:

$$\mathbb{E}[\text{tokens/expert}] = \frac{B \cdot S}{N}$$

当 N 很大时, 即使 $K = 1$, 每个专家仍能收到足够数据。

2.10 Switch Transformer架构图

Switch Transformer (2021) 极简设计

论文: Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity (2021)

Switch Transformer
Architecture
()

2.11 Expert Capacity

问题：Top-1可能导致专家过载

示例：

Token路由：[E1, E1, E1, E1, E1, E2, E3, E3]
Expert 1收到5个token → 过载！

解决：Capacity Factor

$$\text{capacity} = \frac{\text{tokens}}{\text{experts}} \times \text{factor}$$

示例：8 tokens, 4 experts, factor=1.25

- $\text{capacity} = (8/4) \times 1.25 = 3$

规则：每个专家最多处理3个token

阶段四: 2024 工业落地

历史背景: 开源大模型竞争

2024年的技术环境:

- 开源模型竞争: LLaMA、Mistral、DeepSeek等
- 推理成本关注: 模型部署和推理成本成为关键
- 效果与效率平衡: 需要在性能和成本之间找到平衡
- 工程成熟: MoE训练和部署技术成熟

核心问题: 如何在保证效果的前提下, 优化推理成本?

设计趋势: 回归Top-2, 精细化设计

2.12 Mixtral 8x7B – 开源标杆

配置： $N = 8$, $K = 2$ ，每层MoE

指标	数值
总参数	47B
激活参数	13B (28%)
效果	接近 LLaMA-2 70B
推理成本	接近 13B模型

2.12 Mixtral架构图

Mixtral 8x7B 完整架构

论文：Mixtral of Experts (Mistral AI, 2024)

Mixtral 8x7B
Architecture
(□□□□□□□□)

2.12 Mixtral性能对比

模型	参数	激活	性能	成本
LLaMA-2 7B	7B	7B	基准	1x
LLaMA-2 70B	70B	70B	+40%	10x
Mixtral 8x7B	47B	13B	+35%	~2x

优势： 接近70B性能，但成本接近13B

2.13 DeepSeek-MoE – 精细化设计

DeepSeek在MoE领域的突出贡献：两大核心创新，显著提升训练稳定性和模型性能

2.13 DeepSeek创新1: Fine-Grained Experts

细粒度专家设计

维度	传统MoE	DeepSeek-MoE	优势
专家数量	8个大专家	64个小专家	更灵活的组合
激活数	Top-2	Top-6	更细粒度的专业化
专家容量	~7B/专家	~2.3B/专家	更好的负载均衡

核心思想：用更多小专家替代少量大专家

优势：

- 更灵活的路由：64个专家提供更多组合可能
- 更好的专业化：小专家更容易学习特定模式
- 更稳定的训练：负载分布更均匀

2.13 DeepSeek创新2: Shared Experts

共享专家架构

设计: 部分专家始终激活, 学习通用知识

数学表达:

$$y = E_{shared}(x) + \sum_{i \in \text{TopK}} g_i(x) \cdot E_i(x)$$

架构: Shared Experts (始终激活) + Routed Experts (Top-6 from 64) → 合并输出

2.13 Shared Experts的重要性

解决的核心问题

问题	传统MoE	Shared Expert方案
Cold Start	训练初期专家都差不多	Shared提供warm start
Rich-get-richer	热门专家越来越强	Shared分担通用任务
训练不稳定	容易collapse	Shared提供保底机制

实证支持

- DeepSeek-V3: 1个shared + 256个sparse experts
- Google Gemini: 采用shared expert设计
- 训练稳定性: 显著提升 
- 收敛速度: 更快 

历史意义: Shared Expert成为现代MoE的标准设计

2.13 DeepSeek架构图

DeepSeek-MoE 完整架构

DeepSeek-MoE
Architecture
(□□□□□□□□)

2.14 DeepSeek–V3.2 – 最新突破（2025）

发布时间：2025年12月

核心创新：DeepSeek Sparse Attention (DSA) + MoE优化

主要特点

维度	创新	影响
稀疏注意力	DSA机制, $O(L^2) \rightarrow O(Lk)$	长文本处理效率大幅提升
推理能力	接近GPT-5, 略低于Gemini-3.0-Pro	达到国际先进水平
输出效率	相比Kimi-K2输出更短	节省计算资源和等待时间
工具调用	思考模式+工具调用融合	Agent场景能力增强

DeepSeek Sparse Attention (DSA)

核心思想：稀疏注意力替代全量注意力

数学表达：

$$\text{复杂度} = \begin{cases} O(L^2) & \text{传统 Attention} \\ O(Lk) & \text{DSA (k 为稀疏因子)} \end{cases}$$

Part 3: 现代MoE架构全景

3.1 完整架构图

MoE Transformer Layer 经典架构

MoE Transformer Layer
Architecture
(□□□□□□□□)

3.1 架构讲解

关键设计决策

组件	设计	原因
Attention	共享，非MoE	Attention计算量相对较小， MoE收益有限
FFN	MoE化	FFN占计算量的主要部分 (~2/3)， MoE收益大
残差连接	两层都有	保持梯度流动， 训练稳定性
Top-K	K=2	效果与效率的最佳平衡

数据流说明

- 1. 输入： $[B, S, d_{model}]$ 的token序列
- 2. Attention： 所有token共享， 计算全局依赖
- 3. Router： 为每个token选择Top-2专家
- 4. Expert FFN： 只计算选中的2个专家
- 5. 加权融合： 使用门控权重合并专家输出
- 6. 残差连接： 保持信息流动

3.2 各阶段对比总结

阶段	年份	关键创新	解决的问题
原始MoE	1991	混合专家概念	分而治之
Sparse Gated	2017	稀疏激活、Noisy Top-K、辅助损失	计算效率、专家坍塌、负载均衡
Switch	2021	Top-1、Capacity Factor、规模化	训练简化、专家过载、万亿参数
Mixtral	2024	回归Top-2、工业落地	效果效率平衡
DeepSeek	2024	细粒度专家、共享专家	训练稳定性突破
DeepSeek-V3.2	2025	DSA稀疏注意力+MoE	双重稀疏，效率突破

3.3 关键数字

模型	总参数	激活参数	专家数	Top-K
Mixtral 8x7B	46.7B	12.9B	8	2
DeepSeek-MoE	145B	22B	64+2	6
DeepSeek-V3	—	—	256+1	—
DeepSeek-V3.2	—	—	MoE+DSA	双重稀疏

典型效率提升：

- 参数效率：3-4x（相同效果，更少计算）
- 训练效率：2-3x（相同计算，更好效果）

Part 4: 总结与展望

4.1 核心演进脉络

1991 → 问题：计算量没减少，专家坍塌

2017 → 问题：规模受限，不够稳定

2021 → 问题：Top-1效果受限

2024 Mixtral → 工业落地，回归Top-2

2024 DeepSeek → 训练稳定性突破，细粒度+共享专家

2025 DeepSeek-V3.2 → DSA稀疏注意力+MoE，双重稀疏优化

4.2 设计选择指南

维度	选择	说明
专家数量	8-16	中等规模，平衡效率
	64+	细粒度控制（DeepSeek）
Top-K	K=1	最高效率，可能欠拟合
	K=2	主流选择，效果效率平衡
	K>2	很少使用
层配置	每层MoE	Mixtral风格，参数最大化
	交替使用	Switch风格，平衡计算

Q&A

Q: MoE比Dense模型好在哪?

A: 相同计算预算下, MoE可以有更多参数, 从而学到更多知识。本质是"参数换计算"的trade-off。

Q: 为什么Attention不用MoE?

A: Attention的计算量与序列长度平方成正比, 用MoE节省有限。FFN占总计算的2/3, 收益更大。

Q: MoE适合所有场景吗?

A: 不是。推理时需加载全部专家, 显存要求高。小batch时效率优势不明显。

感谢聆听！